

Actividad 2. Análisis Descriptivo con Meta AI

Prompt 1. Explica cuándo es preferible utilizar la Mediana en lugar de la Media en una distribución de datos para reportar resultados y por qué.

Usamos la **mediana** en lugar de la **media** cuando los datos no se portan "bien": tienen valores extremos, están sesgados o no son simétricos.

¿Por qué? La diferencia clave

	Media	Mediana
Qué es	Suma de todos los valores ÷ cantidad de valores	El valor que queda justo en el centro cuando ordenas todo
Sensibilidad	Muy sensible a valores atípicos/outliers	Robusta, casi no le afectan los extremos
Mejor para	Datos simétricos, sin extremos raros	Datos sesgados o con valores muy altos/bajos

Cuándo es preferible usar la mediana

1. Cuando hay valores atípicos o extremos

La media se "jala" hacia los extremos. La mediana no.

Ejemplo: Sueldos en una startup de 5 personas

\$20k, \$22k, \$25k, \$28k, \$500k ← el CEO

- **Media:** \$119k. Decir "el sueldo promedio es \$119k" suena engañoso, 4 de 5 ganan <\$30k
- **Mediana:** \$25k. Refleja mucho mejor lo que gana una persona "típica" ahí

2. Cuando la distribución está sesgada

Ingreso, precio de casas, tiempo de espera, población de ciudades... casi siempre están sesgados a la derecha: muchos valores bajos y pocos muy altos.

En una distribución sesgada a la derecha: **Media > Mediana**

En una distribución sesgada a la izquierda: **Media < Mediana**

Si media y mediana son muy diferentes, es señal de sesgo y la mediana suele describir mejor el "centro".

3. Cuando trabajas con datos ordinales

Si tus datos son categorías con orden pero sin distancia exacta, como "Malo, Regular, Bueno, Excelente" o escala Likert 1-5, no tiene sentido sumar y dividir. Pero sí puedes decir "la mediana fue Bueno".

4. Cuando quieres reportar algo resistente a manipulación

Si reportas ingreso promedio de un barrio y entra un billonario, la media se dispara. La mediana apenas se mueve. Por eso el INEGI reporta "ingreso mediano por hogar" en México.

Regla práctica para decidir

1. **Grafica tus datos** o al menos saca media y mediana
2. **Si media $\approx$ mediana:** distribución bastante simétrica. Usa la media, es más potente estadísticamente
3. **Si son muy diferentes:** hay sesgo u outliers. Usa la mediana para describir "lo típico" y reporta ambas para transparencia

Tip pro: Cuando ves reportes de "precio mediano de casas en CDMX" en vez de promedio, es justo por esto. Una mansión de \$80 MDP no debe hacerte pensar que un depa típico cuesta \$40 MDP **Ciudad de México.**

Prompt 2. ¿Cómo se relaciona un histograma, un gráfico de caja y la visualización de la desviación estándar con un gráfico de dispersión para el análisis de univariable?

Un gráfico de dispersión es bivariable —necesita dos variables: X vs Y. En cambio, un histograma, un gráfico de caja y la desviación estándar son herramientas univariadas —describen una sola variable a la vez.

Pero sí se relacionan. Lo que haces es usar el gráfico de dispersión para "descomponer" tu análisis univariable o para ver cómo se comporta una variable en función de otra.

1. Histograma vs Gráfico de dispersión

El histograma te muestra la *forma de la distribución* de una sola variable: dónde se concentran los datos, si hay sesgo, si es multimodal.

Relación con dispersión: Si haces un gráfico de dispersión de `índice vs valor`, básicamente estás "desenrollando" el histograma. Y los histogramas marginales son súper comunes: pones un histograma de X arriba del scatter y uno de Y a la derecha. Así ves la distribución de cada variable por separado mientras analizas su relación.

Herramienta	Qué analiza	Qué te dice
Histograma	1 variable	Forma, moda, sesgo, huecos
Dispersión	2 variables	Relación, correlación, outliers bivariantes

2. Gráfico de caja vs Gráfico de dispersión

El boxplot resume tu variable en 5 números: mínimo, Q1, mediana, Q3, máximo. Te da mediana, dispersión con el rango intercuartil IQR, y outliers univariantes.

Relación con dispersión: En un scatter puedes dibujar boxplots marginales en los ejes. O mejor: si agrupas X en intervalos y haces un boxplot de Y para cada intervalo, obtienes un "violin plot discreto". Esto te deja ver cómo cambia la mediana y la dispersión de Y conforme X aumenta. Es la versión univariable condicionada.

La regla del boxplot para outliers es:

$$dato < Q1 - 1.5 \times IQR$$

o

$$dato > Q3 + 1.5 \times IQR$$

. En un scatter, un punto puede no ser outlier en X ni en Y por separado, pero sí ser un outlier bivariable porque rompe la tendencia.

3. Desviación estándar vs Gráfico de dispersión

La desviación estándar

$$s$$

mide qué tan dispersos están los datos respecto a la media

$$\bar{x}$$

:

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Relación con dispersión:

1. **Barras de error:** En un scatter puedes graficar la media de Y para cada valor de X, con barras de o . Eso visualiza la dispersión condicional.

$$\pm 1s$$

$$\pm 2s$$

2. **Elipses de confianza:** Si asumes normalidad bivariable, puedes dibujar elipses de , alrededor del centroide. Te muestra dónde cae el 68%, 95% de los datos si fueran normales.

1s

2s

3. **Regresión:** La línea de regresión en un scatter minimiza la suma de errores al cuadrado. La desviación estándar de esos residuos es el "error típico de estimación" —qué tan dispersos están los puntos respecto a la línea.

La idea clave para análisis univariable

Usas el scatter para hacer análisis univariable *condicionado*. En vez de preguntar "¿cómo se distribuye Y?", preguntas "¿cómo se distribuye Y cuando $X = 3$? ¿Y cuando $X = 7$?"

Entonces:

- **Histograma** → se vuelve histograma condicional por franjas de X
- **Boxplot** → se vuelve serie de boxplots a lo largo de X
- **Desviación estándar** → se vuelve la SD de Y para cada grupo de X

El scatter es el puente para pasar de "qué forma tiene mi variable" a "cómo cambia esa forma cuando otra variable se mueve".

¿Quieres que te ponga un ejemplo con código para visualizar los 4 juntos?

Prompt 3. ¿Cómo un gráfico de calor multivariable ayuda a determinar la mejor correlación entre las mismas variables de una tabla?

Un **gráfico de calor multivariable**, también llamado *heatmap de correlación*, te deja ver de un vistazo qué variables de tu tabla se mueven juntas y cuáles no. Es básicamente tu tabla de correlaciones pintada con colores.

¿Qué muestra exactamente?

Una matriz donde filas y columnas son las mismas variables de tu dataset. Cada celda muestra el coeficiente de correlación entre 2 variables, normalmente Pearson

r

, que va de -1 a 1.

≡ Valor de	Aa Significa	≡ Color típico
1.0	<u>Correlación positiva perfecta</u>	Rojo intenso
0.7 a 0.99	<u>Correlación positiva fuerte</u>	Rojo/naranja
0.3 a 0.69	<u>Correlación positiva moderada</u>	Naranja/amarillo
-0.29 a 0.29	<u>Correlación débil o nula</u>	Blanco/beige
-0.3 a -0.69	<u>Correlación negativa moderada</u>	Celeste
-0.7 a -0.99	<u>Correlación negativa fuerte</u>	Azul intenso
-1.0	<u>Correlación negativa perfecta</u>	Azul intenso

La diagonal siempre es 1.0 porque cada variable tiene correlación perfecta consigo misma.

¿Cómo te ayuda a determinar la "mejor" correlación?

"Mejor" depende de qué busques, pero el heatmap te ayuda en 3 casos clave:

1. Encontrar las relaciones más fuertes

- Escaneas el gráfico y buscas los colores más intensos, rojo o azul oscuro
- Ignoras el signo si solo te importa la fuerza: tanto 0.92 como -0.89 son correlaciones fuertes
- Ejemplo: Si "Horas de estudio" vs "Calificación final" sale rojo intenso con 0.88, ya sabes que esa relación es clave

2. Detectar multicolinealidad para modelos

- Si dos variables predictoras tienen correlación muy alta entre sí, digamos > 0.8 o < -0.8 , meter ambas a una regresión lineal te da problemas
- El heatmap te marca esas parejas con colores fuertes fuera de la diagonal
- Regla práctica: si X_1 y X_2 están correlacionadas a 0.95, quédate con una sola para tu modelo

3. Identificar variables independientes

- Las celdas blancas/beige cercanas a 0 te dicen qué variables no tienen relación lineal
- Útil si buscas diversificar: en finanzas quieres activos con correlación cercana a 0 para reducir riesgo

¿Cómo leerlo paso a paso?

1. **Mira tu variable objetivo:** Ubica la fila o columna de lo que quieres predecir. Ejemplo: "Ventas"
2. **Busca colores intensos en esa fila:** Las variables con rojo fuerte son tus mejores predictores positivos. Azul fuerte = predictores negativos fuertes
3. **Revisa entre predictores:** Mira el resto de la matriz. Si "Inversión en Ads" y "Clicks" están en rojo 0.91 entre sí, están diciendo casi lo mismo
4. **Descarta lo débil:** Todo lo que esté en tonos pálidos < 0.3 no tiene relación lineal útil

Limitaciones que debes tener claras

- **Solo detecta relaciones lineales:** Si la relación es curva tipo , Pearson te dará 0 y el heatmap saldrá blanco, aunque sí exista relación

$$y = x^2$$

- **Correlación $\neq$ causalidad:** Que "Ventas de helado" y "Ahogamientos" tengan no significa que una cause la otra. Ambas suben en verano

$$r = 0.9$$

- **Sensible a outliers:** Un solo dato extremo puede inflar o matar una correlación

Tip práctico: Después de ver el heatmap, grafica un diagrama de dispersión de las 2-3 parejas más fuertes que encuentres. Así confirmas si la relación es realmente lineal o si hay algo raro.

Reflexión.

La diferencia entre media y mediana introduce sutilmente el concepto estadístico de la varianza, pues el análisis estadístico indica si se portan bien (o no) los datos. Esto permite clasificar mejor el comportamiento general de los datos en función de lo que buscamos. Para visualizar adecuadamente este comportamiento se usan rutinas de graficación como los histogramas, graficos de caja, etc. Pueden aprovecharse además para realizar un análisis estadístico y representar visualmente algunos parámetros como la desviación estándar. Una de estas herramientas de graficación son los mapas de calor, que permiten visualizar la calidad de relación entre dos variables.