

Actividad 3. Explorando la Inferencia con Meta AI.

Prompt 1. ¿En qué se diferencia la estadística descriptiva con la estadística inferencial?, ¿Qué papel juega el aprendizaje estadístico dentro de la inferencia?

Las dos son ramas de la estadística, pero tienen objetivos distintos. Piensa en una como "fotografiar" y la otra como "predecir".

Tipo	¿Qué hace?	¿Con qué datos trabaja?	Objetivo	Ejemplos de herramientas
Descriptiva	Resume y organiza los datos que ya tienes	Toda la población o muestra completa	Describir lo observado, sin ir más allá	Media, mediana, desviación estándar, histogramas, tablas de frecuencia
Inferencial	Usa una muestra para sacar conclusiones sobre una población más grande	Solo una muestra	Generalizar, estimar y probar hipótesis con un margen de incertidumbre	Intervalos de confianza, pruebas t, ANOVA, regresión, p-values

Diferencias clave:

- **Alcance:** La descriptiva se queda en tus datos. La inferencial salta de tus datos al resto del mundo.
- **Incertidumbre:** La descriptiva no tiene incertidumbre, es exacta para esos datos. La inferencial siempre reporta incertidumbre: error estándar, nivel de confianza, probabilidad.
- **Pregunta típica:** Descriptiva responde "¿Qué pasó?". Inferencial responde "¿Qué puedo decir de todos basándome en esto?" y "¿Qué tan seguro estoy?".

Ejemplo rápido:

Encuestas a 1000 mexicanos sobre intención de voto.

Descriptiva: "De los 1000 encuestados, 42% prefiere al candidato A".

Inferencial: "Con 95% de confianza, entre 39% y 45% de todos los votantes mexicanos prefiere al candidato A".

¿Qué papel juega el aprendizaje estadístico dentro de la inferencia?

El aprendizaje estadístico es básicamente la caja de herramientas moderna de la inferencia, especialmente cuando los datos son complejos.

1. Mismo objetivo, métodos más flexibles

La inferencia clásica usa modelos con supuestos fuertes: normalidad, linealidad, pocas variables. El aprendizaje estadístico relaja eso. Te deja modelar relaciones no lineales, interactuar con miles de variables y aún así hacer inferencia: estimar efectos, cuantificar incertidumbre, predecir.

2. Dos caras del aprendizaje estadístico

- **Predicción:** Construyes un modelo para predecir y . Aquí usas random forests, redes neuronales, XGBoost. Esto es inferencia predictiva: "dado este perfil, ¿qué valor esperamos para y con qué intervalo?".
- **Inferencia de parámetros:** Quieres entender la relación entre x e y . Usas modelos interpretables como regresión lasso, splines, árboles aditivos. El aprendizaje estadístico aporta técnicas para estimar coeficientes y sus errores cuando $p > n$ o hay colinealidad brutal.

3. Herramientas nuevas para cuantificar incertidumbre

La inferencia clásica te da fórmulas cerradas para el error estándar. En aprendizaje estadístico usas bootstrap, validación cruzada, intervalos de predicción conformal, inferencia bayesiana vía MCMC. Son métodos computacionales para responder "¿qué tan confiable es este resultado?" cuando el modelo es una caja negra.

4. Manejo del sesgo-varianza

La estadística inferencial clásica se preocupa por estimadores insesgados. El aprendizaje estadístico acepta un poco de sesgo a cambio de mucha menos varianza. Ahí entra la regularización: ridge, lasso. Sigue siendo inferencia, pero con otro trade-off.

En resumen: Si la inferencia es el juego de "usar una muestra para hablar de la población", el aprendizaje estadístico es la expansión del reglamento. Te da modelos para datos desordenados y métodos computacionales para seguir respondiendo la pregunta central: ¿qué puedo afirmar y con qué grado de confianza?

Prompt 2. ¿Por qué el valor de 0.05 (5%) es el estándar de oro para el p-value en la mayoría de las investigaciones? ¿Qué pasaría si usáramos un estándar más relajado, como 0.10 (10%)?.

El 0.05 como "estándar de oro" tiene más de historia y convención que de matemática pura. No hay una ley universal que diga que 5% es el número correcto.

¿Por qué 0.05 se volvió el estándar?

1. **R.A. Fisher en los años 1920s:** Él popularizó el uso de p-values en estadística experimental. En su libro *Statistical Methods for Research Workers* de 1925, mencionó casualmente que "un estándar conveniente" para considerar algo significativo sería 1 en 20, o sea 0.05. No lo justificó con una derivación matemática profunda. Simplemente le pareció un punto de corte razonable.
2. **Balance entre errores:** Un test de hipótesis tiene dos errores posibles:

Error	Qué significa	Consecuencia
Tipo I (falso positivo)	Dices que hay efecto cuando no lo hay	Publicas basura, desperdicias recursos siguiendo pistas falsas
Tipo II (falso negativo)	Dices que no hay efecto cuando sí lo hay	Pierdes descubrimientos reales

Fisher y compañía querían ser conservadores. 5% de probabilidad de falso positivo les pareció un compromiso decente: suficientemente estricto para no inundar la literatura de ruido, pero no tan estricto que nunca encuentres nada.

1. **Inercia académica:** Una vez que miles de papers, libros de texto y software lo adoptaron, cambiarlo es difícilísimo. Revistas, revisores y universidades lo esperan. Se volvió la "moneda común" para comparar estudios.

¿Qué pasaría si usamos 0.10 en lugar de 0.05?

Usar $\alpha = 0.10$ relaja el criterio. Estos son los trade-offs:

Lo que ganas:

1. **Más poder estadístico:** Es más fácil rechazar la hipótesis nula. Con el mismo tamaño de muestra, detectas efectos más pequeños. Esto ayuda en campos donde reclutar participantes es caro o difícil, como ensayos clínicos con enfermedades raras.
2. **Menos falsos negativos:** Dejas pasar menos descubrimientos reales. Si tu costo de "perderte algo" es alto, 0.10 tiene sentido.

Lo que pierdes:

1. **El doble de falsos positivos:** Por definición, si no hay efecto real, con $\alpha = 0.10$ tienes 10% de probabilidad de decir "sí hay" vs 5% con el estándar actual. La literatura se llenaría del doble de resultados espurios.
2. **Crisis de replicación peor:** Ya tenemos problemas de reproducibilidad con 0.05. Con 0.10, ~10% de todos los estudios nulos darían significativo solo por azar. Los meta-análisis se volverían mucho más ruidosos.
3. **Credibilidad:** La gente desconfiaría más. " $p < 0.10$ " ya suena a "casi significativo" en muchos papers hoy, y los revisores lo ven con sospecha.

Entonces, ¿0.05 es mágico?

Para nada. Es arbitrario. De hecho, varios campos ya se desviaron:

- **Física de partículas:** Usan "5 sigma" = $p \approx 0.0000003$ para anunciar descubrimientos como el bosón de Higgs. Con 0.05 habrían "descubierto" cientos de partículas falsas.
- **Genómica/GWAS:** Usan $p < 5 \times 10^{-8}$ por las correcciones de múltiples comparaciones. 0.05 sería inútil con 1 millón de tests.

- **Estudios exploratorios:** Algunos ya reportan $p < 0.10$ y lo justifican diciendo que es investigación preliminar. El truco es ser transparente.

La idea clave

El nivel de alfa debería depender de los costos relativos de cada error en tu contexto específico. Fisher mismo dijo que el investigador debe elegir el nivel según las circunstancias.

Regla práctica: Si un falso positivo te cuesta mucho dinero, vidas, o políticas públicas dañinas → usa 0.01 o menos. Si un falso negativo significa perder una cura potencial y tienes forma de confirmar después → 0.10 puede ser defendible. Pero dilo explícitamente y prepárate para que te pidan replicar.

El problema real no es 0.05 vs 0.10. Es que mucha gente trata al p-value como un veredicto binario de "real vs falso", cuando solo es una pieza de evidencia. El tamaño del efecto, los intervalos de confianza y la pre-registración importan más.

¿Quieres que hagamos el cálculo de cuántos más falsos positivos tendrías con 0.10 usando un ejemplo concreto?

Prompt 3. ¿Cómo se relaciona una correlación de bivariable con una regresión lineal simple?, ¿Cómo actúa el algoritmo del descenso de gradiente como optimizador para una regresión?.

1. Correlación bivariable vs Regresión lineal simple

Ambas analizan la relación entre 2 variables X e Y, pero miden cosas distintas:

≡ Concepto	⌘ Correlación bivariable	≡ Regresión lineal simple	📎 Files
Qué mide	<u>Fuerza y dirección de la relación lineal</u>	Cómo Y cambia en promedio cuando X cambia 1 unidad	
Simetría	<u>Simétrica:</u>	Asimétrica: Y depende de X. Regresar Y sobre X ≠ X sobre Y	

≡ Concepto	Aa Correlación bivariable	≡ Regresión lineal simple	📎 Files
Resultado	<u>Un solo número entre -1 y 1</u>	Una ecuación:	
Unidades	<u>Sin unidades, estandarizada</u>	tiene unidades: unidades de Y / unidades de X	
Propósito	<u>¿Están relacionadas?</u>	¿Cuánto cambia Y si muevo X? + Predecir Y	

Relación matemática clave

Están conectadas directamente. La pendiente



de la regresión es la correlación escalada por las desviaciones estándar:



Y además:



. O sea, el cuadrado de la correlación es el % de varianza de Y que la regresión explica.

En resumen: Correlación te dice "qué tan alineados están los puntos". Regresión te da la "mejor línea" que pasa por esos puntos para predecir.

2. Descenso de gradiente como optimizador para regresión

La regresión lineal busca



y



que minimicen el error. El error que se usa es el

Error Cuadrático Medio

, ECM:



Esa función



es como un valle. El descenso de gradiente es el algoritmo que "baja el valle" hasta el punto más bajo.

Cómo actúa, paso a paso:

1. **Inicializa:** Empieza con valores al azar, ej. , .



2. **Calcula el gradiente:** El gradiente es la pendiente del valle en ese punto. Son las derivadas parciales que te dicen "hacia dónde sube más el error":



1. **Actualiza los parámetros:** Te mueves en dirección contraria al gradiente, dando un "pasito" de tamaño , llamado *tasa de aprendizaje*:



1. **Repite:** Vuelve al paso 2 con los nuevos . Cada iteración el error ECM debería bajar.



Analogía rápida: Imagina que estás vendado en una montaña con niebla y quieres llegar al punto más bajo. Tocas el suelo alrededor con el pie para sentir hacia dónde baja más la pendiente = gradiente. Das un paso en esa dirección = actualización. Repites hasta que el suelo esté plano = mínimo.

Dato importante

: Para regresión lineal simple, el ECM tiene un solo mínimo global. Así que descenso de gradiente siempre llega a la misma solución que la fórmula cerrada



. La ventaja del descenso de gradiente aparece cuando tienes 1000 variables y la fórmula cerrada es imposible de calcular.¿Quieres que te muestre con un ejemplo numérico cómo se van moviendo



y



en 3 iteraciones?

Reflexión.

El análisis estadístico permite describir o proyectar el comportamiento de los datos. Sin embargo deben existir ciertos estándares y convenciones para que se pueda "confiar" o no en algún grupo de datos, como las cotas sobre los p-values.

Al analizar un conjunto de datos es posible realizar una predicción sobre la evolución de estos en el tiempo (o alguna otra variable). Esta predicción, liderada

por un modelo, puede ser exitosa o no, tomando en cuenta algunos indicadores estadísticos.