

Actividad 3. Exploración de Datos con Meta AI.

Prompt 1. ¿Cuáles son las principales estrategias para detectar y tratar valores atípicos (outliers) en un dataset numérico? Explica en qué situaciones es correcto eliminarlos con el método del Rango Intercuartílico (IQR), cuándo es preferible aplicar una transformación como logaritmo o raíz cuadrada, y cuándo lo más adecuado es conservarlos porque representan fenómenos reales del negocio.

Detectar y tratar outliers (valor atípico) no es aplicar una fórmula y ya, es decidir qué historia quieres que tu modelo aprenda. El número raro en la tabla siempre viene de tres lugares posibles: un error, una distorsión de escala, o un evento real pero poco frecuente. La estrategia cambia según cuál sea.

Primero, cómo los encuentras sin cegarte con el método. Lo que funciona es mirar antes de medir. Un histograma te dice si la cola es larga hacia la derecha, un boxplot te muestra dónde la caja se rompe. Ahí el rango intercuartílico, el famoso IQR, aparece de forma natural: tomas Q1 y Q3, calculas la distancia entre ellos, y marcas como sospechosos los puntos que caen más allá de Q1 menos 1.5 veces esa distancia o Q3 más 1.5 veces. Es una regla robusta porque no usa la media, usa la mediana, entonces un par de valores extremos no la mueven.

Si tus datos se parecen a una campana, el z-score también sirve, pero en la práctica casi ningún dato de negocio es normal. Para cosas multivariantes, donde un cliente no es raro por edad ni por gasto por separado sino por la combinación, ahí ya no alcanza IQR y necesitas algo que mire distancias, como isolation forest. Pero la parte crítica no es el algoritmo, es preguntar después: ¿este punto tiene sentido en el proceso que lo generó?

Cuándo sí tiene sentido borrar con IQR. Imagina que trabajas con sensores de temperatura de una cámara fría en la Ciudad de México. La mayoría marca entre 2

y 6 grados, y de pronto aparece un 98. No es un día caluroso, es un fallo de lectura. O en un CRM, alguien escribió la edad como 230 porque se le fue un cero. Ahí el IQR funciona bien porque la distribución real es compacta, casi simétrica alrededor de la mediana, y el valor está físicamente fuera del rango operativo. También es correcto cuando el outlier es muy poco frecuente, menos del 1 por ciento, y estás entrenando un modelo muy sensible a la distancia como una regresión lineal o un k-means, donde un solo punto puede arrastrar la pendiente o mover un centroide. En esos casos borrar no es esconder la realidad, es quitar ruido que sabes que no volverá a ocurrir.

El error común es usar IQR en datos naturalmente asimétricos. Si aplicas la regla a ingresos mensuales, te va a marcar como outlier a todos los clientes que ganan más de 80 mil pesos. No son errores, es la cola real de la distribución.

Ahí entra la transformación, y por eso el logaritmo o la raíz cuadrada son tan útiles. Cuando la variable crece de forma multiplicativa, no aditiva, los valores grandes no son errores, solo están en otra escala. Ventas por ticket, tiempo de espera en soporte, número de sesiones en una app: todos tienen cola derecha larga, varianza que aumenta con la media, y unos pocos casos que dominan la media.

Aplicar log no borra al cliente que gastó 200 mil, lo acerca. Convierte diferencias absolutas en proporciones, entonces pasar de 1,000 a 2,000 pesa lo mismo que pasar de 10,000 a 20,000. El modelo deja de obsesionarse con el más grande y empieza a aprender patrones en toda la base. La raíz cuadrada hace algo parecido pero más suave, y es la opción clásica para conteos, como número de visitas o de productos en carrito, donde hay muchos ceros y unos pocos dieces.

Usas transformación cuando el negocio te dice que esos valores extremos importan pero no quieres que distorsionen. Un banco no va a eliminar a sus clientes de banca privada porque rompen el IQR, los va a log-transformar para que el modelo de riesgo vea la relación sin que un solo patrimonio de ocho cifras se coma todo el ajuste. La desventaja es que luego tienes que interpretar en escala logarítmica, y eso hay que explicarlo bien al equipo.

Y luego está el tercer caso, el más delicado: cuando el outlier es precisamente lo que te interesa. En fraude, en churn de alto valor, en fallas de maquinaria, en picos de demanda por Hot Sale, el punto raro no es ruido, es la señal. Si tienes una base de transacciones y borras con IQR el 0.3 por ciento más alto, acabas de

borrar todos los fraudes. Si quitas los tiempos de entrega de 48 horas en temporada de lluvias en CDMX, tu modelo va a prometer entregas imposibles.

En estos escenarios no transformas para esconderlo ni lo borras. Lo conservas y cambias la forma de modelar. Puedes crear una bandera binaria que indique "es valor extremo", puedes segmentar y entrenar un modelo aparte para la cola, o puedes elegir algoritmos robustos que no se dejan arrastrar por la media, como árboles, medianas móviles o regresiones con pérdida Huber. La idea es que el modelo aprenda que esos eventos existen, son raros y tienen consecuencias distintas.

La decisión final nunca es estadística pura. Pregúntate: si mañana vuelve a aparecer este valor, ¿mi operación lo trataría como error o como oportunidad? Si es error, IQR y fuera. Si es real pero está en otra escala, transforma. Si es real y es el corazón del negocio, consérvalo y haz que el modelo lo respete.

Esa conversación con el área de negocio es la que separa limpiar datos de mutilarlos.

Conclusión: Es importante distinguir las posibles interpretaciones de un outlier pues sobre estos valores puede recaer información valiosa. Para esto es necesario dominar el uso de las representaciones gráficas de los datos. Es vital para uno como analista de datos tener una rutina de graficación predefinida para ciertos tipos de bases de datos.

Prompt 2. ¿Qué diferencia existe entre el coeficiente de correlación de Pearson y el de Spearman, y cuándo se recomienda usar cada uno? Proporciona un ejemplo de una correlación alta que sea espuria (falsa) y explica por qué la regla "correlación no implica causalidad" es fundamental en el análisis de datos.

Diferencia entre Pearson y Spearman

≡ Propiedad	≡ Coeficiente de Pearson	≡ Coeficiente de Spearman	Aa Title
Qué mide	Relación <i>lineal</i> entre 2 variables	Relación <i>monotónica</i> entre 2 variables. Monotónica = siempre sube o siempre baja, pero no necesariamente en línea recta	<u>Sin título</u>
Datos que usa	Valores numéricos reales	Rangos/orden de los datos. Convierte los valores a 1º, 2º, 3º... y luego calcula Pearson sobre esos rangos	<u>Sin título</u>
Supuestos	1. Variables continuas 2. Relación lineal 3. Datos ~normales 4. Sin outliers extremos	Solo requiere que los datos sean ordinales o continuos. No asume linealidad ni normalidad	<u>Sin título</u>
Sensible a outliers	Muy sensible. Un solo valor extremo puede cambiar drásticamente	Robusto. Los outliers se vuelven solo "el más alto" y afectan menos	<u>Sin título</u>
Rango	a	a	<u>Sin título</u>

Cuándo usar cada uno:

1. **Pearson:** Úsalo cuando esperas que la relación sea lineal y tus datos son continuos, sin outliers fuertes, y razonablemente normales.

Ejemplo: Relación entre horas de estudio y calificación en examen, altura vs peso en adultos.

2. **Spearman**: Úsalo cuando:

- La relación es monotónica pero no lineal. Ej: curva de aprendizaje - al inicio mejoras mucho con pocas horas, después cada hora extra suma menos.
- Tienes outliers que no quieres eliminar.
- Tus datos son ordinales. Ej: escala de satisfacción 1-5 vs gasto mensual.
- No se cumple normalidad y tu muestra es pequeña.

Dato clave: Si Pearson $\approx$ Spearman, la relación probablemente es lineal. Si Spearman es mucho mayor que Pearson, tienes relación monotónica no lineal.

Ejemplo de correlación alta espuria

Correlación: Número de películas en las que actúa Nicolas Cage por año vs número de personas que se ahogan al caer en una piscina en EE.UU., 1999-2009.

$$r \approx 0.66$$

— una correlación alta

Por qué es espuria: No existe mecanismo causal. Que Cage filme más películas no hace que la gente se ahogue más. Ambos suben y bajan por pura coincidencia o por una tercera variable oculta: por ejemplo, factores económicos o poblacionales que variaron en esos años. Se llama "correlación espuria" cuando dos variables se mueven juntas pero sin relación real.

Otros clásicos: consumo de helado vs ataques de tiburones. Ambos suben en verano. La causa real es la temperatura.

Por qué "correlación no implica causalidad" es fundamental

1. Existen 3 explicaciones posibles para cualquier correlación

Si A y B están correlacionados, puede ser que:

- A causa B
- B causa A → causalidad inversa. Ej: más bomberos en un incendio se correlaciona con más daño, pero el daño causa que manden bomberos, no al revés
- C causa A y B → tercera variable. Ej: helado y tiburones, donde C = verano/temperatura

2. Decisiones erróneas cuestan dinero y vidas

Si crees que “dormir con zapatos causa dolor de cabeza” porque hay correlación, prohibir zapatos en la cama no sirve. La causa real: llegar borracho a dormir. En medicina, confundir correlación con causa llevó a recomendar terapia hormonal en menopausia porque mujeres que la usaban tenían menos infartos. Ensayos controlados mostraron que en realidad *aumentaba* el riesgo. La correlación existía porque mujeres con más acceso a salud usaban la terapia.

3. La causalidad requiere más evidencia:

Para afirmar causa necesitas: correlación, precedencia temporal, descartar terceras variables, y idealmente experimentos controlados. La correlación es solo el primer paso.

Regla práctica

: Usa correlación para generar hipótesis, no conclusiones. Cuando veas

$$r = 0.9$$

, pregunta “¿qué más podría explicar esto?” antes de actuar.

Conclusiones: El entendimiento de las correlaciones es el primer paso para analizar a mayor profundidad los datos. Las correlaciones nos permiten entender mejor el comportamiento de

ambas variables, sin embargo hay que tener mucho cuidado pues no se puede determinar directamente la causalidad de una acción a partir de la correlación pues es requerido entender mejor los datos haciendo un análisis mas profundo en búsqueda de negar o confirmar esta conclusión.

Prompt 3. ¿Qué es el storytelling con datos y cómo se aplica en la presentación de un Análisis Exploratorio de Datos (EDA) para una audiencia no técnica?

Menciona al menos 3 principios clave para transformar un conjunto de gráficos estadísticos en una narrativa visual coherente y convincente.

Storytelling con datos es el arte de combinar datos, visuales y narrativa para comunicar insights de forma que la audiencia no solo entienda los números, sino que también sienta por qué importan y qué debería pasar después.

En lugar de aventar 15 gráficas y esperar que la gente conecte los puntos, tú haces el trabajo de guía: seleccionas qué mostrar, en qué orden, y cuál es el "¿y entonces qué?"

Cuando haces un **EDA** - Análisis Exploratorio de Datos - tu objetivo técnico es entender el dataset. Pero cuando lo *presentas* a una audiencia no técnica, tu objetivo cambia: es persuadir, alinear y motivar decisiones. Ahí entra el storytelling.

¿Cómo se aplica en la presentación de un EDA a gente no técnica?

En un EDA técnico típicamente exploras distribución, correlaciones, outliers, missing data, etc. Para una audiencia no técnica, haces una curaduría de ese trabajo:

1. **Empiezas con el problema de negocio, no con el dataset** Técnico: "El dataset tiene 50k filas y 23 variables" Storytelling: "Queríamos entender por qué perdimos 18% de clientes el trimestre pasado"

2. **Solo muestras los 3-4 hallazgos que cambian la decisión** En tu EDA encuentras 20 patrones. En la presentación usas solo los que explican el problema y apuntan a una acción.
3. **Ordenas los gráficos como una trama: contexto → conflicto → resolución** No es un dump de gráficos. Es: "Así estábamos → Aquí encontramos algo raro → Esto lo explica → Si hacemos X, ganamos Y"
4. **Traduces el lenguaje estadístico** "Correlación de Pearson de -0.73" → "Cuando el tiempo de respuesta sube, la satisfacción del cliente se desploma"
"p-value < 0.05" → "Estamos 95% seguros de que esto no es casualidad"

3 principios clave para transformar gráficos estadísticos en narrativa visual

1. Define un mensaje por visual: El principio de "1 gráfico = 1 idea"

Un error común en EDAs es meter density plots, boxplots y heatmaps con 10 anotaciones. La gente no técnica se pierde.

Cómo aplicarlo:

- Ponle a cada gráfico un título que sea la conclusión, no la descripción.
- Mal: "Distribución de edad de clientes"
- Bien: **"60% de los clientes que cancelan tienen menos de 30 años"**
- Elimina todo lo que no soporte ese mensaje: leyendas extra, ejes secundarios, gridlines ruidosas. Si no ayuda a contar esa idea, estorba.

En un EDA: En lugar de mostrar el histograma completo de todas las edades, filtras y destacas con color solo el grupo <30 y anotas: "Este grupo cancela 3x más".

2. Estructura narrativa: Contexto → Tensión → Resolución

Los humanos recordamos historias, no listas de hechos. Tu set de gráficos debe tener arco narrativo.

Cómo aplicarlo:

Etapa	Qué haces en EDA	Ejemplo visual
Contexto	Establece la línea base	Gráfico 1: "Las ventas cayeron 18% en Q2". Línea simple de tiempo.
Tensión	Muestra el hallazgo inesperado del EDA	Gráfico 2: "Pero solo cayó en la región Norte". Barras comparando regiones.
Resolución	Explica el porqué + implicación	Gráfico 3: "En Norte, 80% de pedidos tardaron +5 días". Scatter + línea de referencia. Terminas con: "Si reducimos entrega a 2 días, recuperamos \$2M"

En un EDA: Tus gráficos de outliers, correlaciones y segmentaciones se reordenan para que cada uno responda "¿y qué?" del anterior.

3. Humaniza el dato: Ancla los números a personas, dinero o tiempo

"La media bajó 0.4" no mueve a nadie. "Perdemos 1 de cada 5 clientes nuevos" sí.

Cómo aplicarlo:

- **Cambia unidades:** De % a "personas". De coeficientes a "\$ perdidos/ganados". En vez de: "Churn rate 22%" → "De cada 100 clientes nuevos, 22 se van antes del mes 3"
- **Usa anotaciones y callouts:** Encierra con un círculo el dato clave y escribe en lenguaje natural qué significa. Ejemplo: En un boxplot de tiempo de entrega, flecha apuntando al outlier diciendo "Estos 200 pedidos tardaron 9 días → causaron 70% de las quejas"
- **Antes/después:** Muestra el estado actual vs el potencial. La brecha crea urgencia. "Hoy: 5 días promedio. Con el cambio: 2 días. Impacto: +\$1.2M anuales"

En un EDA: Tus diagramas de dispersión dejan de ser nubes de puntos y se vuelven "cada punto es un cliente que perdimos por esta razón".

Bonus: Errores que matan la narrativa en EDA para no técnicos

1. **Jerga estadística sin traducir:** R^2 , heterocedasticidad, kurtosis. Cambia a "qué tan bien explica esto el resultado".

2. **Demasiados gráficos:** Si tienes más de 5 slides con datos, estás explorando, no comunicando. El EDA completo va en anexo.
3. **Empezar con la metodología:** A la directora de Marketing no le importa que usaste K-means. Le importa que "hay 3 tipos de clientes y al tipo 2 lo estamos perdiendo".

Regla de oro: Si quitas el gráfico y tu historia sigue teniendo sentido, ese gráfico sobraba. Si quitas la historia y solo dejas gráficos, nadie sabrá qué hacer el lunes.

Conclusión: Desplegar múltiples gráficos pueden ser de beneficio para uno como analista, sin embargo, al momento de presentar resultados es importante ser lo mas claros, minimalistas y precisos posible. Para lograr esto es necesario comprender la idea planteada detrás de cada gráfica, cuadro comparativo o método de visualización para el público pues ahí radica el mensaje que se quiere comunicar mas allá del análisis general.